

```
In [45]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as sts
import math
%matplotlib inline
```

**Рассматривается следующая параметрическая модель:  $X_1, \dots, X_N$  — выборка из распределения  $N(\theta, 1)$ . Известно, что  $\theta$  близко к нулю: с вероятностью не менее 0.95 выполнено неравенство  $|\theta| < 0.5$ .**

В чём суть байесовского метода? Выжать как можно информации (из экспертов, условия задачи, гороскопа, etc.) о том, как ведёт себя  $\theta$  и использовать её.

**Посмотрим, что можно сказать про априорное распределение  $\theta$ :**

Общеизвестно, что в интервал  $[-2\sigma_0, 2\sigma_0]$  при  $N(\mu_0, \sigma_0^2)$  входит около 95% выборки

Значит, логично предположить, что априорное распределение - нормальное.

Тогда мы знаем кое-что о его дисперсии:

$$\rightarrow 2\sigma_0 = 0.5 \rightarrow \sigma_0 = 0.25$$

В качестве  $\mu_0$  возьмём 0, потому что можем.

Значит,  $\theta \sim N(\mu_0, \sigma_0^2) = N(0, 0.0625)$  - априорное распределение  $\theta$

**Сгенерируйте выборку размера 100 из распределения Коши с нулевым параметром сдвига и с параметром масштаба равным 1. При  $N = 100$  используйте эту выборку в качестве  $X_1, \dots, X_N$  для описанной выше модели.**

**Посчитайте байесовские оценки (для одного априорного распределения, учитывающего описанное выше свойство) и оценки максимального правдоподобия для всех  $n \leq 100$ . Постройте графики абсолютной величины отклонения этих оценок от истинного значения параметра  $\theta_0 = 0$  в зависимости от  $n$ . Сделайте выводы.**

Знаем, что  $\sigma_0^2 = 1$  для исходной выборки. Получим байесовскую оценку  $\theta$ .

Как и в предыдущей задаче, апостериорное - сопряженное к априорному нормальное с параметрами :

$$\left( \frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^n x_i}{\sigma^2} \right) / \left( \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right), \left( \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}$$

$$= \left( \frac{\sum_{i=1}^n x_i}{\sigma^2} \right) / \left( \frac{1}{0.0625} + \frac{n}{\sigma^2} \right), \left( \frac{1}{0.0625} + \frac{n}{\sigma^2} \right)^{-1}$$

Мы хотим получить условное матожидание апостериорного при данной выборке, то есть

$$\theta^* = \frac{\sum_{i=1}^n x_i}{\frac{1}{0.0625} + n}$$

```
In [91]: big_sample = sts.cauchy.rvs(loc=0., scale=1., size=100)
```

```
In [100]: sigma_0 = 0.25
def bayes_estimator(X_array):
    return np.sum(X_array)*1./(sigma_0**-2. + 1.*len(X_array))

def likelihood_estimator(X_array):
    return np.mean(X_array)
```

```
In [ ]:
```

```
In [ ]:
```

```
In [101]: bayes_values = []  
          likelihood_values = []  
  
          for i in np.arange(1, len(big_sample)):  
              sample = big_sample[:i]  
              bayes_values.append(bayes_estimator(sample))  
              likelihood_values.append(likelihood_estimator(sample))
```


```
In [102]: X = np.arange(1, 100)

# Y = [np.abs(likelihood_values[i-1] - bayes_values[i-1])
#      for i in np.arange(1, len(big_sample))
#      ]

plt.figure(figsize=(20,10))
trash = plt.plot(X, np.abs(bayes_values), label='|bayes|(n)')
trash = plt.plot(X, np.abs(likelihood_values), label='|likelihood|(n)')

plt.legend()
```

Out[102]: <matplotlib.legend.Legend at 0x125967510>




## Посмотрим поближе

```
In [103]: plt.figure(figsize=(20,10))
plt.ylim((0., 2.))
trash = plt.plot(X, np.abs(bayes_values), color='g', label='|bayes|(n)')
trash = plt.plot(X, np.abs(likelihood_values), color='b', label='|likelihood|(n)')

plt.legend()
```

Out[103]: <matplotlib.legend.Legend at 0x125f0c110>



**Вывод:**

Байесовская оценка ведет себя стабильно лучше, чем оценка максимального правдоподобия, потому что мы использовали знание об априорном распределении и обладали большей информацией. Однако оценка всё равно не очень хорошая и происходит по большому счёту бред, потому что мы неверно угадали класс распределения (Коши вместо нормального).

In [ ]: